

Résumé synthétique du rapport de stage

Réseaux de neurones pour la modélisation de la dynamique des véhicules

Benabdelaziz Melissa – Master 2 EEA, Mesure et traitement de l'information – 2024/2025

Objectif du stage

Le stage réalisé au CRAN / IUT de Longwy porte sur la modélisation de la dynamique d'un véhicule autonome miniature, le QCar de Quanser. L'objectif est de construire un modèle intelligent capable de prédire l'évolution des grandeurs dynamiques du véhicule afin d'améliorer le contrôle, l'estimation d'état et la sécurité des véhicules autonomes.


Le travail suit une logique hybride : mise en place de la simulation Quanser, préparation de données dynamiques, entraînement d'un réseau récurrent, puis ajout d'une contrainte physique pour rendre les prédictions plus cohérentes avec les lois de la mécanique.

873 136 séquences
données temporelles préparées

GRU 150 + Dense 150
modèle retenu


Résidu 1.00 à 0.42
gain de cohérence physique

Images importantes à retenir



Plateforme QCar

Capteurs, actionneurs et calcul embarqué forment le support expérimental du projet.




Modèle bicycle

Base mécanique utilisée pour générer une donnée propre et exploitable pour l'apprentissage.

Layer (type)	Output Shape	Param #
gru (GRU)	(None, 150)	72,980
dense (Dense)	(None, 150)	22,650
dense_1 (Dense)	(None, 5)	755

Architecture du réseau

Le bloc GRU apprend les dépendances temporelles entre commandes et états du véhicule.



Validation des prédictions

La comparaison prédiction / vérité terrain vérifie le suivi de la vitesse longitudinale.

Lecture rapide du rapport

1. Simuler

configuration Quanser, QCar virtuel, scénarios de conduite

2. Apprendre

séquences temporelles, modèle GRU, prédiction multi-sorties

3. Contraindre

perte physics-informed pour réduire le résidu mécanique

Démarche technique

Simulation QCar

Installation de Quanser Interactive Labs et du SDK, création de scénarios de navigation, tests leader-follower et contrôle vitesse / direction.

Collecte de données

Acquisition à 100 Hz des commandes et états du véhicule. Les limites du simulateur ont conduit à exploiter aussi un modèle bicycle déjà disponible.

Prétraitement

Normalisation des variables, création de séquences de 5 pas de temps, séparation en entraînement, validation et test.

Apprentissage

Réseau GRU adapté aux dépendances temporelles, prédisant v_x , v_y , $\dot{\psi}$, a_x et a_y au pas suivant.

Résultats principaux

Modèle GRU de base. Bonne précision statistique sur le jeu de test.

Métrique test	Valeur
MSE	0.0023
MAE	0.038
R^2	0.989
Meilleure époque	312
Paramètres	96 305

Avec contrainte physique. La perte totale combine erreur MSE et résidu mécanique.

Test	Sans	Avec
MSE	0.0023	0.0026
MAE	0.038	0.041
R^2	0.989	0.987
Résidu physique	1.00	0.42
Meilleure époque	312	370

Interprétation. La contrainte physique augmente légèrement l'erreur statistique, mais elle réduit fortement l'incohérence mécanique. Le modèle devient donc plus plausible pour une future intégration dans un observateur d'état ou une boucle de contrôle embarquée.

Conclusion et perspectives

Le stage valide une chaîne complète : simulation QCar, génération de données, apprentissage GRU et apprentissage informé par la physique. Le modèle apprend correctement l'évolution temporelle du véhicule, tandis que le terme physique améliore la robustesse et l'interprétabilité.

Les suites prioritaires sont la validation sur données réelles bruitées, l'ajout de lois physiques plus riches, le réglage automatique du poids λ , puis l'intégration du modèle dans une architecture d'estimation et de contrôle pour véhicule autonome.

Message central : combiner deep learning et contraintes physiques permet d'obtenir un modèle précis, plus crédible mécaniquement et mieux adapté aux applications de conduite autonome.